



Tecnológico de Monterrey

Momento de Retroalimentación: Módulo 2

**Implementación de una técnica de aprendizaje máquina
sin el uso de un framework**

Ana Paula Moreno Frías | A01751886

02 de septiembre del 2026

Inteligencia Artificial Avanzada para la Ciencia de Datos

Profesor: Jorge Ramírez Uresti

Objetivo

El objetivo de esta actividad fue implementar un algoritmo de Machine Learning sin utilizar un framework para la construcción del modelo. En este caso, se utilizó Random Forest con el objetivo de predecir si un cliente incumplirá el pago de su tarjeta de crédito.

Se utilizó el dataset “Default of Credit Card Clients”, que contiene información sobre los clientes, su crédito y su historial de pagos.


Análisis de los datos

El dataset contiene 30,000 observaciones y 25 variables. Al revisar los datos no se encontraron valores faltantes ni registros duplicados.


La variable que se busca predecir es “default payment next month”, donde:

- 0 representa No Default.
- 1 representa Default.

Al analizar esta variable se encontró que el 77.88% de los clientes no presentó default, mientras que el 22.12% sí lo presentó. Esto indica que existe un desbalance entre las dos clases.



También se analizó la relación entre el historial de pagos y el default. Una de las variables que mostró una relación importante fue “pay_0” que representa el estado de pago más reciente.



Se puede observar que los clientes que presentan mayores retrasos en sus pagos tienden a presentar un mayor porcentaje de default.

Preprocesamiento

Antes de entrenar el modelo se realizaron algunos cambios en los datos:

- Se eliminó la columna “ID” ya que solamente identifica a cada cliente y no aporta información para realizar la predicción.
- Se agruparon algunas categorías especiales de “EDUCATION” y “MARRIAGE” dentro de la categoría Others.
- Después se separaron las variables predictoras (X) de la variable objetivo (Y). Los datos se dividieron de forma estratificada en 70% para entrenamiento y 30% para prueba, buscando mantener una distribución similar de Default y No Default en ambos conjuntos.

Implementación de Random Forest

El algoritmo fue implementado desde cero sin utilizar un framework de Machine Learning para construir el modelo, los pasos fueron los siguientes:

- Primero se implementaron los árboles de decisión. Para encontrar la mejor división de cada nodo se utilizan la entropía y la ganancia de información.

- En cada división se selecciona de forma aleatoria un subconjunto de características.
- Para construir el Random Forest se entrenan varios árboles. Cada uno utiliza una muestra diferente de los datos obtenida mediante bootstrap, es decir, un muestreo aleatorio con reemplazo.
- Finalmente, cada árbol realiza una predicción y el resultado final del Random Forest se obtiene mediante voto mayoritario.

Para esta implementación se utilizaron los siguientes parámetros:


- Número de árboles: 5
- Profundidad máxima: 6
- Mínimo de observaciones para una división: 20
- Máximo de características consideradas: 5

Evaluación del modelo

Se realizaron predicciones utilizando los datos de prueba debido a que era una implementación desde cero y para evaluar el desempeño se utilizaron las siguientes métricas:

- Accuracy
- Precision
- Recall
- F1-score

Matriz de confusión



Análisis de resultados

El modelo obtuvo un accuracy de 81.6%, lo que indica que clasificó correctamente una gran parte de las observaciones del conjunto de prueba. La precision fue de 68.23%, lo que significa que, de los clientes que el modelo identificó como default, aproximadamente el 68% realmente presentó incumplimiento.

Por otro lado, el recall fue de 31.49%, mostrando que el modelo logró detectar alrededor de una tercera parte de todos los clientes que realmente presentaron default. Esto se observa también en la matriz de confusión, donde se identificaron correctamente 627 casos de Default, mientras que 1,364 fueron clasificados como No Default.

Finalmente, el F1-score fue de 43.09%, reflejando la diferencia entre precision y recall. En general, aunque el modelo presenta un buen accuracy, su capacidad para detectar la clase default es menor. Por esta razón, es importante considerar todas las métricas y no únicamente el porcentaje total de predicciones correctas al evaluar el desempeño del modelo.

Para evaluar el desempeño del modelo se utilizaron principalmente recall y F1-score. El recall permite conocer qué proporción de los clientes que realmente presentan default logra identificar

el modelo, mientras que el F1-score permite evaluar el balance entre precision y recall. Estas métricas son especialmente útiles debido al desbalance existente entre las clases.

Conclusión

En conclusión, la implementación de Random Forest desde cero permitió comprender de manera práctica el funcionamiento del algoritmo y sus principales componentes. Aunque el modelo obtuvo un accuracy de 81.6%, los resultados muestran que no logra clasificar correctamente ambas clases por igual debido al desbalance presente en los datos. En particular, presenta mayor dificultad para identificar a los clientes que realmente presentan default, lo cual se refleja en el recall de 31.49%. Esto demuestra la importancia de considerar el balance de las clases y utilizar diferentes métricas para evaluar correctamente el desempeño de un modelo de clasificación.